

Fase 1: Definição do Projeto

Tema: Impacto da Geração Distribuída Solar na Tarifa de Energia Elétrica (Conta de Luz) no Brasil

Disciplina: Hands-On Fundamentos de Dados e Analytics, MBA em Engenharia de Dados (Mackenzie)

Data: 15/08/2026

1. Definição do problema e escolha do caso de uso

1.1 Contexto (por que o tema é atual)

- O Brasil ultrapassou **4 milhões de sistemas fotovoltaicos** em operação na geração distribuída (GD), somando **44,6 GW** de potência instalada e beneficiando mais de **7,1 milhões de unidades consumidoras**, marca atingida em 2026 ([Canal Solar](#), [PV Magazine Brasil](#)).
- Só no 1º trimestre de 2026 foram conectados **2.177 MW** em GD solar, com uma média de **8,8 mil novos sistemas por dia** ([PV Magazine Brasil](#)).
- Esse crescimento acelera o debate sobre quem paga a manutenção da rede elétrica (o chamado “Fio B”, regulado pela Lei 14.300) à medida que mais consumidores geram sua própria energia e reduzem o consumo faturado pelas distribuidoras, um problema real de sustentabilidade financeira do setor.
- Paralelamente, o valor da conta de luz de quem **não** tem painel solar depende do acionamento mensal das **bandeiras tarifárias**, definido pelas condições hidrológicas do Sistema Interligado Nacional (SIN) ([ANEEL Dados Abertos](#)).

1.2 Problema de negócio

Distribuidoras, reguladores e o próprio consumidor final têm dificuldade em antecipar como a expansão acelerada da geração distribuída solar e as condições hidrológicas do país vão pressionar o valor da tarifa de energia (conta de luz) nos próximos meses e anos, hoje essa leitura é fragmentada entre diferentes fontes e não é combinada de forma sistemática.

1.3 Impacto para o negócio

A distorção tarifária afeta diretamente o caixa das distribuidoras (que perdem receita de consumidores com GD, mas mantêm o custo fixo da rede) e o bolso dos consumidores sem geração própria, que absorvem parte do custo via bandeiras tarifárias e realocação de tarifas. Sem visibilidade preditiva, decisões de política tarifária e de investimento em energia solar são tomadas de forma reativa.

1.4 Objetivo geral

Construir um pipeline de dados e um modelo preditivo que relacione a evolução da geração distribuída solar, as condições hidrológicas e a estrutura tarifária das distribuidoras, permitindo antecipar o comportamento da conta de luz no Brasil.

1.5 Objetivos específicos (sugestão de 4)

1. Consolidar em uma única base histórica o crescimento da geração distribuída solar por estado/região e sua relação com a tarifa (TE/TUSD) praticada pelas distribuidoras locais.
2. Modelar a relação entre o nível de Energia Natural Afluente (ENA/hidrologia) e o acionamento histórico das bandeiras tarifárias (classificação: verde, amarela, vermelha P1/P2).
3. Identificar clusters de estados/distribuidoras por perfil de penetração solar versus estrutura tarifária (quem já sente mais impacto da GD na receita).
4. Construir um dashboard que estime, para os próximos meses, a probabilidade de acionamento de bandeira e a tendência tarifária por região.

1.6 Setor de atuação

Energia (regulado, setor público-privado); se o formulário do briefing não tiver essa opção nativa, marcar “Outro: Energia”.

2. Seleção e avaliação das bases de dados

Base	Fonte	Formato	Granularidade	Cobertura temporal	Atualização	Avaliação
Bandeiras Tarifárias (acionamento, adicional, conta bandeira)	ANEEL Dados Abertos	CSV + dicionário ou PDF	Nacional, mensal	Desde jan/2015	Mensal (última atualização: 10/ago/2026)	Boa: série longa e oficial, mas granularidade nacional única, precisa ser enriquecida para gerar features suficientes.
Relação de Empreendimentos de Geração Distribuída	ANEEL Dados Abertos	CSV, ZIP e Parquet (já otimizado para big data)	Por empreendimento (potência, fonte, data de conexão)	Desde dez/2008	Diária	Excelente: alto volume (milhões de registros dado o marco de 4M+ sistemas), formato Parquet nativo, atualizado todo dia. Ponto de atenção de governança: avaliar se há identificação de unidade consumidora e, se sim, tratar/agregar por município para reduzir sensibilidade.

Base	Fonte	Formato	Granularidade	Cobertura temporal	Atualização	Avaliação
Tarifas Homologadas das Distribuidoras (TE e TUSD)	ANEEL Dados Abertos	CSV + XML	Por distribuidora, por processo de reajuste	Histórico dos reajustes tarifários	Conforme homologação da ANEEL	Boa: permite calcular o valor efetivo da conta de luz por distribuidora/região ao longo do tempo.
ENA Diário por Reservatório / por Bacia (Energia Natural Afluente)	ONS Dados Abertos	CSV, XLSX e Parquet	Diária, por reservatório e por bacia hidroenergética	Desde 2005	Diária	Excelente: é o principal driver técnico por trás do acionamento das bandeiras, combinação direta com a base de bandeiras para a modelagem preditiva.
(complementar) Malha municipal / população: IBGE	IBGE	CSV/API	Município	Censo/estimativas anuais	Anual	Útil para normalizar penetração de GD per capita por região, se necessário.

Conclusão da avaliação: as quatro bases principais (bandeiras, GD, tarifas, ENA) são todas públicas, gratuitas, em formatos processáveis (CSV/Parquet), com granularidade diária ou mensal e séries longas o suficiente para modelagem, atendem bem ao requisito de “Big Data Analytics” tanto pelo volume (GD com atualização diária desde 2008) quanto pela necessidade real de integração de múltiplas fontes heterogêneas.

Limitação identificada: as páginas de metadados da ANEEL não expõem publicamente o dicionário de campos nem o volume exato de linhas, isso só é confirmado baixando o arquivo. Recomendo que o grupo baixe uma amostra de cada base já na próxima etapa (avaliação técnica) para validar o schema antes de fechar a arquitetura definitiva.

3. Desenho inicial da arquitetura

O fluxo de dados segue quatro camadas em sequência, da ingestão até o consumo final em modelagem e dashboard, conforme resumido na tabela abaixo.

Etapa	Descrição
1. Fontes (Ingestão)	ANEEL (Bandeiras, GD, Tarifas) e ONS (ENA), acessadas via download/API em formatos CSV, Parquet e XML.
2. Camada Raw (dados brutos, como estão)	Armazenamento em pasta/bucket organizado por fonte e por data de ingestão (partição diária).

Etapas	Descrição
3. Camada Trusted (dados validados)	Limpeza, padronização de tipos e normalização de nomes de campos/UF; junção por data e UF/distribuidora, deduplicação e checagem de qualidade.
4. Camada Curated/Refined (modelo analítico)	Agregações e features; tabela mensal consolidada de UF, tarifa média, penetração solar, ENA e bandeira.
5a. Modelagem (ML)	Classificação de bandeira e clusterização de UF, a partir da camada Curated/Refined.
5b. Dashboard (consumo)	Power BI ou Looker Studio, com visão executiva e regional, também a partir da camada Curated/Refined.

Governança aplicada: catálogo de dados simples (planilha com fonte, dono, frequência), classificação de sensibilidade da base de GD (avaliar se há UC/CPF/CNPJ e, se houver, mascarar ou agregar por município), e política de acesso básica (camada raw só para o time de dados, curated liberada para todo o grupo).

4. Ferramentas e tecnologias sugeridas

Etapas	Ferramenta sugerida	Por quê
Ingestão/ETL	Python (pandas + requests)	Simples, roda em qualquer máquina do grupo, suficiente para o volume do projeto acadêmico.
Orquestração	Prefect ou scripts agendados (cron)	Evitar Airflow completo a menos que o grupo já tenha familiaridade, pelo custo de setup; foco no tempo do semestre, Airflow é overkill para 4 fontes de dados.
Armazenamento	Parquet local + DuckDB (ou PostgreSQL, se preferirem SQL tradicional)	DuckDB lê Parquet nativamente e é leve, ótimo para simular camadas Raw/Trusted/Curated sem precisar de infraestrutura em nuvem.
Modelagem	Python (scikit-learn): Árvore de Decisão / Random Forest para classificação da bandeira,	Alinhado às opções já previstas no briefing do projeto.

Etapas	Ferramenta sugerida	Por quê
	K-Means para clusterização de UFs	
Dashboard	Power BI ou Google Looker Studio (gratuito)	Looker Studio é gratuito e conecta direto em CSV/Google Sheets; Power BI é mais robusto se alguém do grupo já tiver licença.
Versionamento/ documentação	GitHub (repositório com README, notebooks, código-fonte)	Exigido na seção 9 do briefing.
Gestão do projeto	Trello ou Jira	Ver quadro Kanban sugerido na seção seguinte.

5. Kanban inicial (estrutura sugerida para Trello/Jira)

Colunas: Backlog → A Fazer → Em Andamento → Em Revisão → Concluído

Cartões da Fase 1 (a mover para “Concluído” ao fechar esta etapa):

- Definir problema de negócio e caso de uso
- Levantar e validar as 4 bases de dados (baixar amostras, checar dicionários)
- Desenhar arquitetura de camadas (raw/trusted/curated)
- Definir stack de ferramentas
- Criar repositório GitHub inicial (README e estrutura de pastas)

Cartões da Fase 2 (próxima etapa: Ingestão e Preparação):

- Escrever scripts de ingestão (download automatizado ANEEL e ONS)
- Padronizar schemas e nomes de colunas entre fontes
- Implementar camada Trusted (joins por data/UF)
- Documentar dicionário de dados consolidado

Cartões da Fase 3 (Modelagem e Dashboard):

- EDA (estatística descritiva, correlação ENA x bandeira)
- Treinar modelo de classificação de bandeira
- Treinar clusterização de UFs
- Construir dashboard executivo

- Preparar apresentação final e slides

O quadro pode ser criado diretamente no Trello ou no Jira, conforme a conta que o grupo conectar.

Fontes consultadas

- ANEEL Dados Abertos: Bandeiras Tarifárias: <https://dadosabertos.aneel.gov.br/dataset/bandeiras-tarifarias>
- ANEEL Dados Abertos: Geração Distribuída: <https://dadosabertos.aneel.gov.br/dataset/relacao-de-empreendimentos-de-geracao-distribuida>
- ANEEL Dados Abertos: Tarifas das Distribuidoras: <https://dadosabertos.aneel.gov.br/dataset/tarifas-distribuidoras-energia-eletrica>
- ONS Dados Abertos: ENA Diário por Reservatório: <https://dados.ons.org.br/dataset/ena-diario-por-reservatorio>
- Canal Solar: Brasil ultrapassa 4 milhões de sistemas de energia solar distribuída: <https://canalsolar.com.br/brasil-quatro-milhoes-sistemas-energia-solar/>
- PV Magazine Brasil: Geração distribuída ultrapassa 4 milhões de sistemas: <https://www.pv-magazine-brasil.com/2026/02/27/geracao-distribuida-ultrapassa-4-milhoes-de-sistemas-no-brasil/>
- PV Magazine Brasil: Brasil adiciona 4,4 GW de capacidade solar no 1º trimestre: <https://www.pv-magazine-brasil.com/2026/05/14/brasil-adiciona-44-gw-de-capacidade-solar-no-primeiro-trimestre/>